

Chapitre 2 : L'Architecture Transformer et la Révolution de l'IA

L'architecture Transformer a été dévoilée au monde par une équipe de chercheurs de Google en 2017 dans l'article historique intitulé 'Attention is All You Need'. Cette découverte a provoqué un véritable séisme dans le domaine du Deep Learning et du NLP.

Avant les Transformers, les architectures dominantes pour traiter les séquences de texte étaient les Réseaux de Neurones Récurrents (RNN) et les réseaux LSTM. Le problème majeur de ces anciennes architectures était leur nature séquentielle : pour comprendre le 10ème mot d'une phrase, le réseau devait d'abord calculer les 9 mots précédents un par un.

L'innovation fondamentale du Transformer est le mécanisme de 'Self-Attention' (Auto-Attention). Ce mécanisme permet au modèle de regarder l'intégralité de la phrase d'un seul coup et d'évaluer mathématiquement quelles parties de la phrase sont connectées entre elles, peu importe leur distance dans le texte.

Le fait que le Transformer n'ait pas besoin de lire les mots dans l'ordre de manière séquentielle lui confère un avantage énorme : il est massivement parallélisable. Cela signifie qu'on peut l'entraîner sur des milliers de cartes graphiques (GPU) simultanément. C'est ce qui a permis de créer des modèles gigantesques entraînés sur des portions massives de l'internet.

Deux familles principales ont émergé de cette architecture. D'une part, les modèles de type Encodeur comme BERT (Bidirectional Encoder Representations from Transformers), qui sont excellents pour comprendre le contexte, classifier du texte, ou extraire des réponses. D'autre part, les modèles de type Décodeur comme GPT (Generative Pre-trained Transformer), qui sont spécialisés dans la génération de texte de manière auto-régressive.