

Chapitre 3 : RAG (Retrieval-Augmented Generation)

Le RAG, ou Retrieval-Augmented Generation (Génération Augmentée par la Recherche), est un paradigme novateur conçu pour pallier les défauts inhérents des grands modèles de langage (LLM).

Malgré leur impressionnante capacité à générer du texte fluide, les LLM classiques souffrent de plusieurs problèmes critiques. Ils ont une date de coupure de leurs connaissances (ils ignorent ce qui s'est passé après leur entraînement), ils ne peuvent pas accéder à des données privées ou confidentielles d'une entreprise, et surtout, ils sont sujets aux 'hallucinations' : ils peuvent affirmer avec aplomb des faits totalement faux.

L'architecture RAG résout ces problèmes en introduisant une étape de recherche (Retrieval) avant la génération de texte. Le processus se divise en plusieurs phases clés :

1. L'indexation : Les documents de l'entreprise (PDF, pages web, bases de données) sont découpés en petits morceaux (chunks). Chaque morceau est transformé en un vecteur mathématique (embedding) grâce à un modèle NLP d'encodage, puis stocké dans une base de données vectorielle spécialisée comme FAISS, ChromaDB ou Pinecone.
2. La recherche : Lorsqu'un utilisateur pose une question, cette question est également transformée en vecteur. La base de données recherche alors les morceaux de texte dont les vecteurs sont mathématiquement les plus proches (similarité cosinus) de la question.
3. La génération : Les morceaux de texte retrouvés (le contexte) sont fusionnés avec la question originale de l'utilisateur pour former un super-prompt. Ce prompt est envoyé au LLM avec une consigne stricte du type : 'Réponds à la question en utilisant EXCLUSIVEMENT le contexte fourni ci-dessous'.

Cette méthode combine le meilleur des deux mondes : la précision absolue d'un moteur de recherche documentaire et l'intelligence conversationnelle d'un LLM. Le RAG est aujourd'hui devenu le standard de l'industrie pour déployer des applications d'IA générative en entreprise.